Reconocimiento de Patrones

Universidad de Sonora · Licenciatura en Ciencias de la Computación
Semestre 2027-1 · Prof. Julio Waissman Vilanova

Examen parcial · Unidades 1 a 4

Nombre: _____ **Expediente:** _____

Tiempo: 90 minutos. Total: 100 puntos. Responde en hojas aparte, indicando el número de problema y dejando indicadas las operaciones. Puedes usar calculadora y una hoja tamaño carta con notas escritas a mano por ti. Si te atoras en un inciso, supón el resultado y sigue: los incisos posteriores se califican con tu resultado.

---

1. Un 93 % que no significa nada. (10 puntos)

Un hospital quiere un modelo que, en el momento de dar de alta a un paciente, estime la probabilidad de que vuelva a internarse en los siguientes 30 días. El 8 % de las altas termina en un reingreso. Con 40,000 altas de 2019 a 2024 (un mismo paciente puede tener varias), un analista hizo lo siguiente:

1) Agregó la columna `urgencias_post`: número de visitas del paciente a urgencias en los 30 días posteriores al alta.
2) Rellenó los faltantes de cada columna con su media, calculada con las 40,000 altas.
3) Partió las altas al azar: 80 % para entrenamiento y 20 % para prueba.
4) Probó 200 combinaciones de hiperparámetros y se quedó con la de mayor exactitud en el conjunto de prueba.
5) Reportó: «el modelo tiene una exactitud de 93 % en datos que nunca vio».

(a) Identifica al menos cuatro problemas. Para cada uno, explica en qué sentido distorsiona la conclusión. (6)

(b) Describe, en pasos, un procedimiento correcto para elegir el modelo y estimar su desempeño. (4)

2. Encadenar o compactar. (12 puntos)

Seis puntos en la recta real: 0, 2, 3, 6, 10, 15. Usamos agrupamiento jerárquico aglomerativo con la distancia $|x - x'|$.

(a) Con enlace *simple* (distancia entre los dos puntos más cercanos de cada grupo), escribe en orden qué grupos se unen y a qué altura. Dibuja el dendrograma. (4)

(b) Repite con enlace *completo* (distancia entre los dos puntos más lejanos). (4)

(c) Corta cada dendrograma para obtener dos grupos. ¿Qué grupos salen en cada caso? ¿Qué fenómeno del enlace simple explica la diferencia? (4)

3. Una iteración de EM. (13 puntos)

Ajustamos una mezcla de dos gaussianas en una dimensión con varianzas conocidas y fijas, $\sigma_1^2 = \sigma_2^2 = 1$, a los datos $x = 0,\ 2,\ 3,\ 5$. Empezamos con $\mu_1 = 1$, $\mu_2 = 4$ y $\pi_1 = \pi_2 = 0.5$.

(a) Paso E: calcula la responsabilidad γ_{i1} de la primera componente para cada uno de los cuatro puntos (tres cifras). (4)

(b) Paso M: calcula los nuevos μ_1, μ_2, π_1 y π_2. (4)

(c) Con las responsabilidades fijas, el paso M maximiza $\sum_{i=1}^{n}\sum_{k=1}^{K}\gamma_{ik}\ln\pi_k$ (más términos que no dependen de π), sujeto a $\sum_k \pi_k = 1$. Demuestra que el máximo es $\pi_k = N_k/n$, con $N_k = \sum_i \gamma_{ik}$. (5)

4. La dimensión VC de los tocones. (15 puntos)

Un *tocón de decisión* en $\mathbb{R}^2$ compara una sola coordenada con un umbral:

$$h(\mathbf{x}) = s \cdot \operatorname{sign}(x_j - a), \qquad j \in \{1,2\}, \quad s \in \{-1,+1\}, \quad a \in \mathbb{R}.$$

Supón que los puntos tienen coordenadas distintas entre sí, así que nunca ocurre $x_j = a$.

(a) Si solo se permite $j = 1$, el problema es de una dimensión. Muestra que el número máximo de dicotomías en $N \geq 2$ puntos es $2N$. (3)

(b) Justifica que, con las dos coordenadas, $m_{\mathcal{H}}(N) \leq 4N - 2$. (3)

(c) Concluye que ningún conjunto de 4 puntos se puede romper. ¿Qué cota obtienes para $d_{\text{VC}}(\mathcal{H})$? (3)

(d) Muestra que los puntos $A = (0,1)$, $B = (1,0)$ y $C = (2,2)$ sí se pueden romper: para cada una de las 8 dicotomías da un tocón $(j,\ s,\ a)$ que la produce. (4)

(e) ¿Cuánto vale $d_{\text{VC}}(\mathcal{H})$? Con la regla práctica de la clase, ¿alrededor de cuántos datos pedirías para aprender con tocones? (2)

5. Sesgo y varianza de una constante. (13 puntos)

La función objetivo es $f(x) = x^2$ con $x \sim \mathcal{U}[-1,1]$, sin ruido. Usamos el modelo $\mathcal{H}_0 = \{h(x) = b\}$ y elegimos b por mínimos cuadrados con N datos (x_n, x_n^2). Puedes usar que $\mathbb{E}[x^2] = 1/3$ y $\mathbb{E}[x^4] = 1/5$.

(a) Muestra que la hipótesis aprendida es $g^{(\mathcal{D})}(x) = \frac{1}{N}\sum_n x_n^2$. (2)

(b) Calcula la hipótesis promedio $\bar{g}$, el sesgo $\mathbb{E}_x\big[(\bar{g}(x) - f(x))^2\big]$ y la varianza $\mathbb{E}_x\big[\operatorname{Var}_{\mathcal{D}}\, g^{(\mathcal{D})}(x)\big]$ en función de N. (5)

(c) Con $N = 2$, el modelo $\mathcal{H}_1 = \{h(x) = ax + b\}$ (la recta que pasa por los dos puntos) tiene sesgo 0.20 y varianza 0.33. ¿Cuál de los dos modelos tiene menor $\mathbb{E}_{\mathcal{D}}[E_{\text{out}}]$? ¿No es raro, si $\mathcal{H}_1$ contiene a $\mathcal{H}_0$? (3)

(d) Si ahora $y = x^2 + \epsilon$, con ruido independiente de media cero y varianza σ^2, ¿cómo queda $\mathbb{E}_{\mathcal{D}}[E_{\text{out}}]$ para $\mathcal{H}_0$? (3)

6. Diez puntajes. (12 puntos)

Un clasificador asigna estos puntajes a diez casos de validación, cuatro positivos y seis negativos:

Positivos ($y = 1$)	0.90	0.70	0.55	0.30		
Negativos ($y = 0$)	0.80	0.50	0.40	0.30	0.20	0.10

(a) Si marcamos como positivo todo caso con puntaje ≥ 0.5, ¿cuánto valen TVP, TFP y la precisión? (3)

(b) Calcula el área bajo la curva ROC contando parejas (un positivo y un negativo). Los empates cuentan 1/2. (4)

(c) Supón que los puntajes son probabilidades bien calibradas, que un falso positivo cuesta 2 y un falso negativo cuesta 3. ¿Cuál es el umbral óptimo de Bayes? Calcula el costo total en estos diez casos al marcar como positivo cuando el puntaje es *mayor* que t, para $t = 0.25$, 0.45 y 0.6. ¿Cuál conviene? (5)

7. Bayes ingenuo con seis mensajes. **(12 puntos)**

Vocabulario: *gratis*, *premio*, *hola*, *mañana*. Mensajes de entrenamiento:

Spam	Normal
gratis premio gratis	hola mañana
premio hola	hola hola gratis
gratis gratis mañana	mañana hola

Usamos Bayes ingenuo multinomial con suavizado de Laplace, $\hat{\theta}_{yj} = (N_{yj} + 1)/(N_y + V)$, y previas estimadas con la proporción de mensajes de cada clase.

(a) Estima $\hat{\theta}_{\text{spam},j}$ y $\hat{\theta}_{\text{normal},j}$ para las cuatro palabras. (4)

(b) Calcula $\ln \dfrac{P(\text{spam} \mid \mathbf{x})}{P(\text{normal} \mid \mathbf{x})}$ para el mensaje «premio hola mañana» y la probabilidad de que sea spam. ¿Cómo se clasifica? (4)

(c) ¿Qué pasaría con ese mismo mensaje si no usáramos suavizado? (2)

(d) Escribe los pesos $w_j = \ln(\hat{\theta}_{\text{spam},j}/\hat{\theta}_{\text{normal},j})$. ¿Qué palabra empuja más hacia spam? (2)

8. Una SVM con tres puntos. **(13 puntos)**

Datos: $\mathbf{x}_1 = (0, 0)$ con $y_1 = -1$; $\mathbf{x}_2 = (2, 0)$ con $y_2 = +1$; $\mathbf{x}_3 = (0, 2)$ con $y_3 = +1$.

(a) Verifica que $\mathbf{w} = (1, 1)$, $b = -1$ cumple las restricciones $y_n(\mathbf{w}^\top \mathbf{x}_n + b) \geq 1$ y que las tres se cumplen con igualdad. ¿Cuánto vale el margen $1/\|\mathbf{w}\|$? (4)

(b) Encuentra los multiplicadores $\alpha_n \geq 0$ que cumplen $\mathbf{w} = \sum_n \alpha_n y_n \mathbf{x}_n$ y $\sum_n \alpha_n y_n = 0$. Verifica que el valor del problema dual, $\sum_n \alpha_n - \frac{1}{2}\|\mathbf{w}\|^2$, coincide con el del primal, $\frac{1}{2}\|\mathbf{w}\|^2$. (4)

(c) Da un argumento geométrico de que ningún hiperplano separa estos datos con un margen mayor. (2)

(d) Agregamos $\mathbf{x}_4 = (1, 1)$ con $y_4 = -1$. ¿Siguen siendo linealmente separables? Con el mismo $(\mathbf{w}, b)$, ¿qué holgura ξ_4 necesita ese punto en la SVM de margen suave y está bien o mal clasificado? (3)