Reconocimiento de Patrones

Universidad de Sonora · Licenciatura en Ciencias de la Computación
Semestre 2027-1 · Prof. Julio Waissman Vilanova

Examen rápido 1 · Aprender de datos y preparar atributos

Nombre: _____ **Expediente:** _____

Tiempo: 20 minutos. Responde en esta hoja. Puedes usar calculadora; no se permiten apuntes.

---

1. Del registro al vector. Para predecir el precio de casas tenemos cinco casas de entrenamiento:

Casa	Área (m^2)	Cocina	Barrio
A	70	Buena	Norte
B	90	Regular	Centro
C	—	Excelente	Norte
D	110	Buena	Sur
E	130	Mala	Centro

El *pipeline* trata cada columna así:

- *Área*: imputar los faltantes con la mediana y después estandarizar, $z = (x - \bar{x})/s$, con la desviación estándar s calculada con denominador n (como lo hace `StandardScaler`).
- *Cocina*: codificación ordinal, Mala = 0, Regular = 1, Buena = 2, Excelente = 3.
- *Barrio*: *one-hot* con las categorías en orden alfabético; una categoría que no se vio en el entrenamiento se codifica con puros ceros.

(a) ¿Qué valores aprende el *pipeline* al llamar a `fit` con estas cinco casas? Escribe cada uno.

(b) ¿Cuántas columnas tiene la matriz que entrega el *pipeline*?

(c) Escribe el vector que produce `transform` para cada una de estas casas nuevas:

- F: área 150 m^2, cocina Excelente, barrio Sur.
- G: área desconocida, cocina Regular, barrio Pitic.

(d) Un compañero propone calcular la mediana, la media y la desviación con las siete casas (las de entrenamiento y las de prueba) «para tener más datos». ¿Qué problema tiene la propuesta?

2. ¿Información legítima? Un banco quiere un modelo que, *antes de llamar* a un cliente, estime la probabilidad de que contrate un depósito a plazo, para decidir a quién llamar. Tiene los registros de una campaña anterior.

(a) Marca cada columna como **L** (se puede usar) o **F** (fuga de información) y justifica en una línea.

Columna	L / F	Justificación
`edad`		
`saldo`: saldo promedio anual de la cuenta		
`resultado_previo`: resultado con ese cliente en la campaña *anterior*		
`duracion`: duración de la llamada, en segundos		
`fecha_alta`: fecha en que se abrió el depósito (vacía si no lo contrató)		

(b) Este código reporta una exactitud que será optimista. Señala **dos** problemas (por número de línea) y di cómo corregirlos.

```
1  X = pd.get_dummies(datos.drop(columns="suscribe"))
2  X = SimpleImputer(strategy="median").fit_transform(X)
3  X_ent, X_pru, y_ent, y_pru = train_test_split(X, datos["suscribe"])
4  for C in [0.01, 0.1, 1, 10, 100]:
5      modelo = LogisticRegression(C=C).fit(X_ent, y_ent)
6      print(C, modelo.score(X_pru, y_pru))   # reporto el mejor
```

3. ¿Aprender o programar? Recuerda las tres condiciones para que tenga sentido aprender: hay un patrón, no sabemos escribirlo y tenemos datos que se parecen a los casos futuros. Para cada situación, si alguna condición falla di cuál; si tiene sentido aprender, di el tipo de aprendizaje y qué serían $\mathbf{x}$ y y (si hay y).

(a) Calcular la retención del impuesto sobre la renta de cada empleado en la nómina.

(b) Pronosticar el volumen que entrará a una presa la próxima semana, con el historial de lluvias y escurrimientos.

(c) Elegir los números de la lotería del domingo a partir de los resultados de los últimos 20 años.

(d) Un detector de neumonía entrenado con radiografías de un hospital de Boston, que se usará en clínicas rurales de la sierra de Sonora con otros equipos de rayos X.

(e) Encontrar grupos de clientes con hábitos de compra parecidos, sin categorías definidas de antemano.