Reconocimiento de Patrones

Universidad de Sonora · Licenciatura en Ciencias de la Computación

Semestre 2027-1 · Prof. Julio Waissman Vilanova

Examen rápido 6 · Redes neuronales

Nombre: _____ **Expediente:** _____

Tiempo: 20 minutos. Responde en esta hoja. Puedes usar calculadora; no se permiten apuntes. Deja indicadas las operaciones.

---

1. Hacia atrás en una red diminuta. Una red con dos entradas, dos neuronas ocultas ReLU y una salida lineal, con pérdida $E = \frac{1}{2}(\hat{y} - y)^2$:

$$\mathbf{z}^{(1)} = W^{(1)}\mathbf{x}, \quad \mathbf{a}^{(1)} = \mathrm{ReLU}\left(\mathbf{z}^{(1)}\right), \quad \hat{y} = \mathbf{w}^{(2)\top}\mathbf{a}^{(1)} + b^{(2)},$$

$$W^{(1)} = \begin{pmatrix} 1 & -1 \\ 0.5 & 0.5 \end{pmatrix}, \qquad \mathbf{w}^{(2)} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}, \qquad b^{(2)} = 0.5.$$

El ejemplo es $\mathbf{x} = (1, 2)$ con $y = 1$.

(a) Haz la pasada hacia adelante: $\mathbf{z}^{(1)}$, $\mathbf{a}^{(1)}$, $\hat{y}$ y E.

(b) Haz la pasada hacia atrás: $\delta^{(2)} = \partial E/\partial \hat{y}$, $\partial E/\partial \mathbf{w}^{(2)}$, $\partial E/\partial b^{(2)}$, $\boldsymbol{\delta}^{(1)} = \left(\mathbf{w}^{(2)}\delta^{(2)}\right) \odot \mathrm{ReLU}'\left(\mathbf{z}^{(1)}\right)$ y $\partial E/\partial W^{(1)} = \boldsymbol{\delta}^{(1)}\mathbf{x}^\top$.

(c) La primera fila de $\partial E/\partial W^{(1)}$ salió en ceros. ¿Por qué? Si esa neurona da $z \leq 0$ para *todos* los datos, ¿qué le pasa durante el entrenamiento?

2. Contar en una red convolucional. Imágenes en color de $3 \times 32 \times 32$ (canales $\times$ alto $\times$ ancho) entran a esta red:

capa	detalle
conv 1	8 filtros de 5×5, sin relleno, paso 1, ReLU
max-pooling	2×2, paso 2
conv 2	16 filtros de 3×3, relleno 1, paso 2, ReLU
lineal	aplanar y 10 salidas

Recuerda: $n_{\text{sal}} = \lfloor (n + 2p - k)/s \rfloor + 1$ y $\#\text{parám.} = (C_{\text{ent}}\, k^2 + 1)\, C_{\text{sal}}$.

(a) Escribe el tamaño de la salida y el número de parámetros de cada capa, y el total.

(b) Una capa *densa* que produjera las mismas $8 \times 28 \times 28$ salidas de conv 1 a partir de los $3 \times 32 \times 32$ pixeles, ¿cuántos parámetros tendría? ¿Qué dos ideas explican la diferencia?

(c) ¿De qué tamaño es el campo receptivo de una neurona de conv 2 (el cuadro de la imagen original que influye en ella)? Usa $r_\ell = r_{\ell-1} + (k-1)\, j_{\ell-1}$, $j_\ell = j_{\ell-1}\, s$, con $r_0 = j_0 = 1$.

3. Atención con vectores pequeños. Una consulta $\mathbf{q} = (2, 0, 2, 0)$ se compara con tres claves y sus valores ($d_k = 4$):

$$\mathbf{k}_1 = (1, 0, 1, 0), \quad \mathbf{k}_2 = (0, 1, 0, 1), \quad \mathbf{k}_3 = (1, 1, -1, -1); \qquad \mathbf{v}_1 = (1, 0), \quad \mathbf{v}_2 = (0, 1), \quad \mathbf{v}_3 = (1, 1).$$

(a) Calcula los pesos de atención $\text{softmax}\left(\mathbf{q}^\top \mathbf{k}_i / \sqrt{d_k}\right)$ y la salida $\sum_i a_i \mathbf{v}_i$.

(b) Repite el cálculo de los pesos *sin* dividir entre $\sqrt{d_k}$. ¿Qué cambia? ¿Por qué eso es un problema cuando d_k es grande (por ejemplo, 64)?

(c) Si la consulta es de la posición 2 en una autoatención con *máscara causal*, y las claves son de las posiciones 1, 2 y 3, ¿cuáles son los pesos y la salida?